RAPPORT TECHNIQUE

Travel Order Resolver NLP

Extraction de Villes pour Réservations de Train

Comparaison : spaCy vs Qwen2.5 vs Qwen2.5+ChromaDB RAG

RÉSULTATS CLÉS

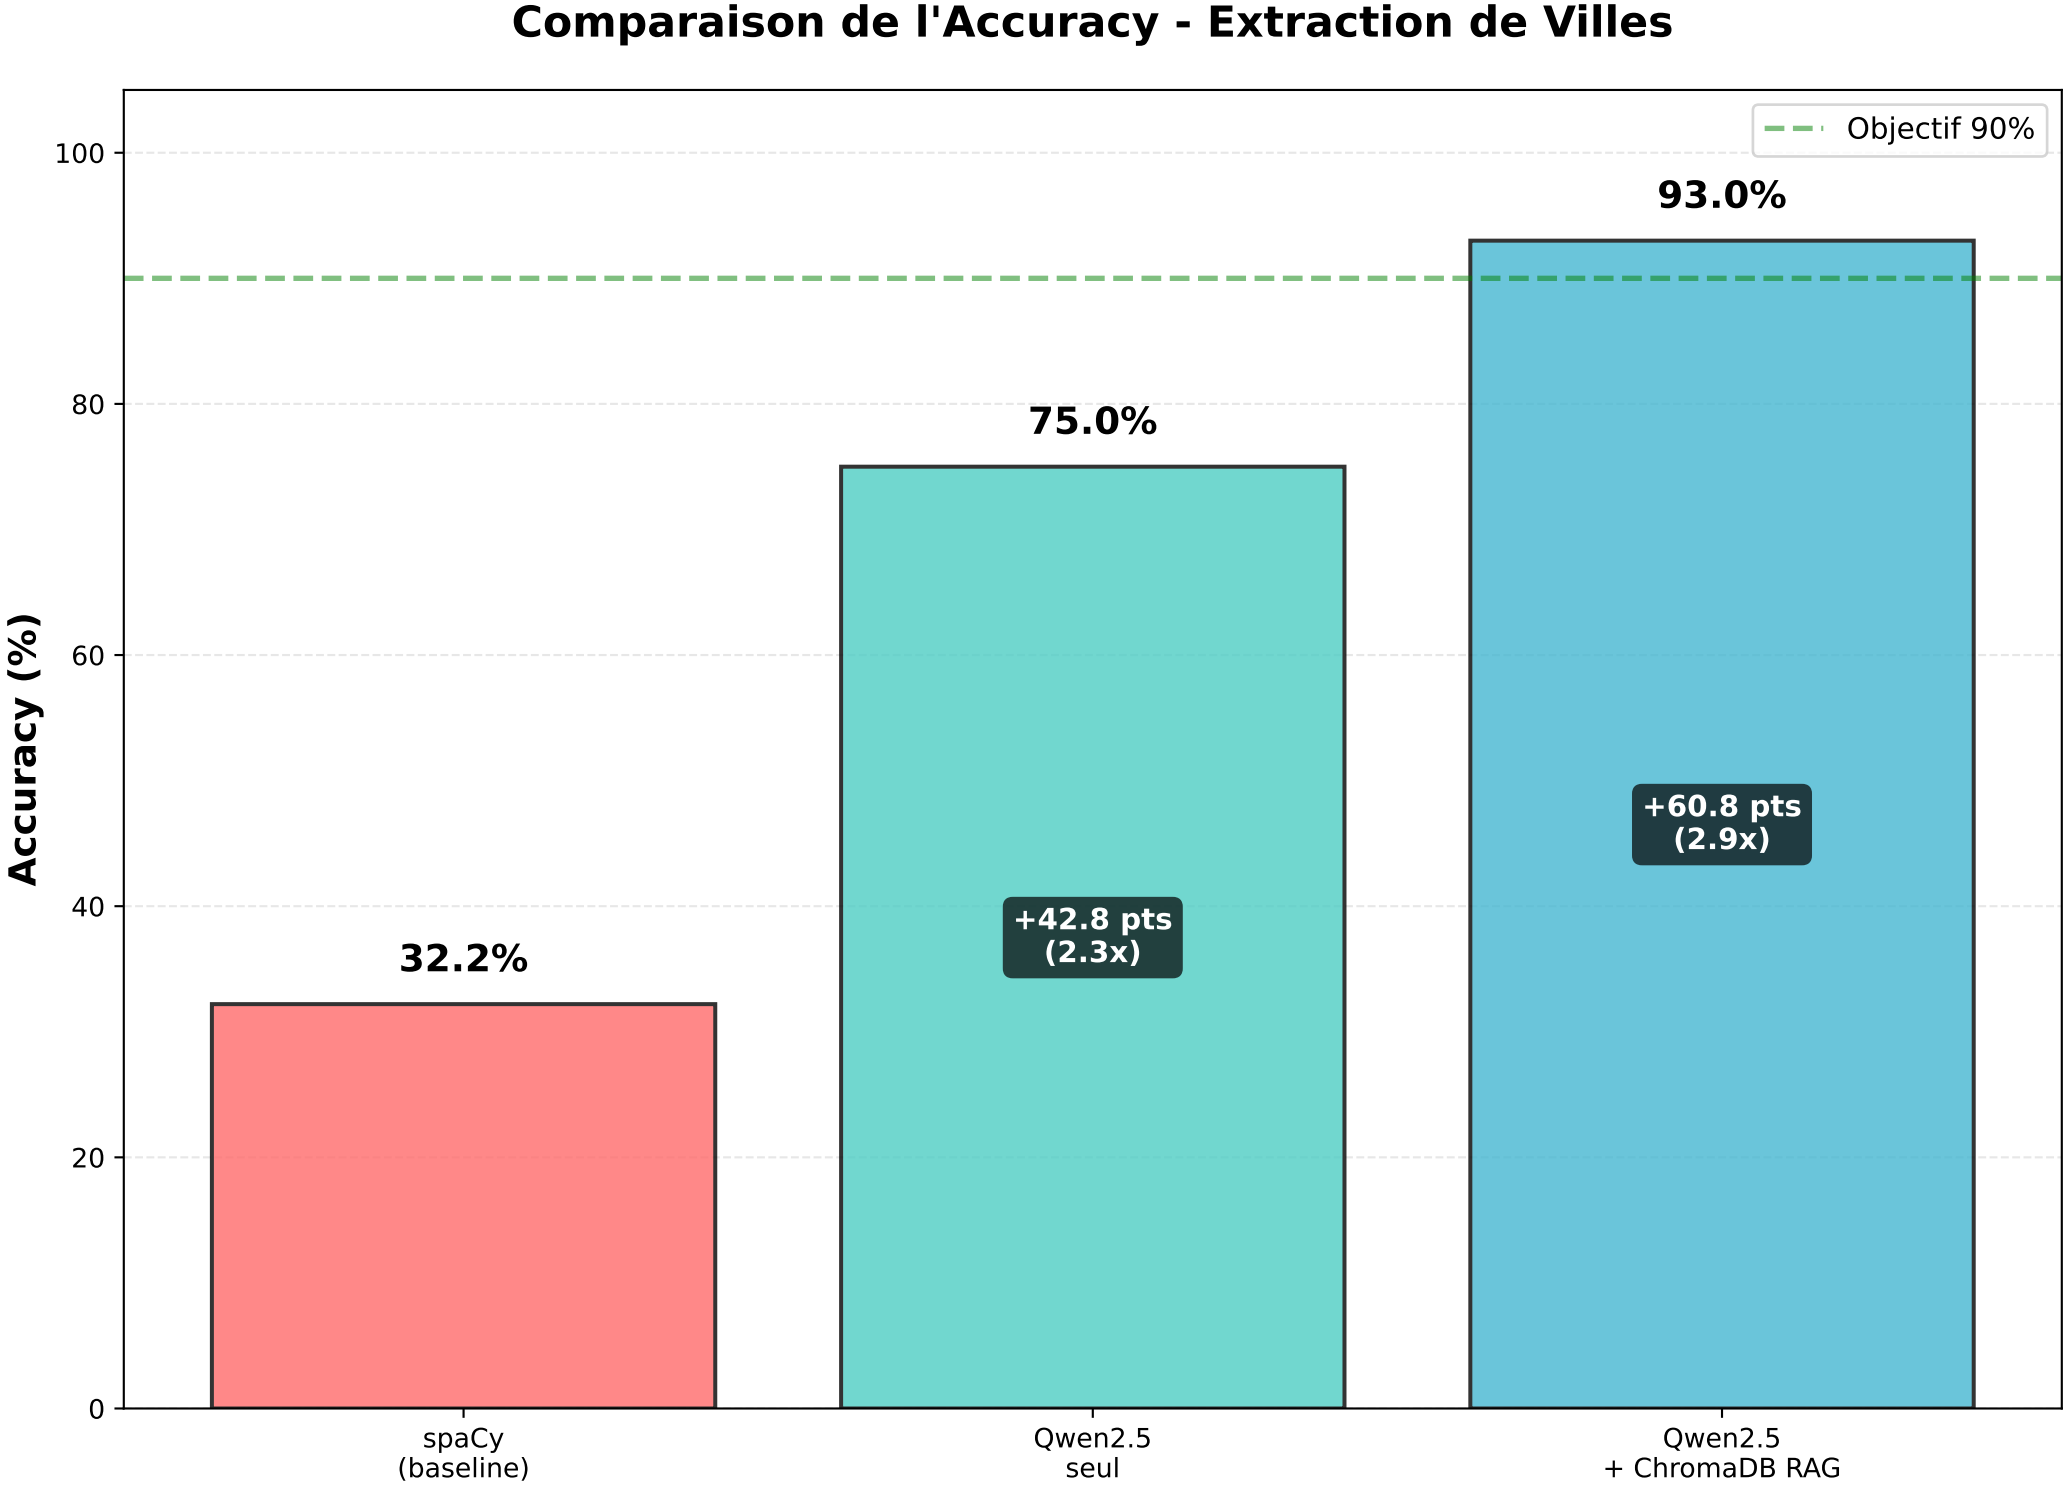
✅ Accuracy: 93.0% avec Qwen2.5 + ChromaDB RAG

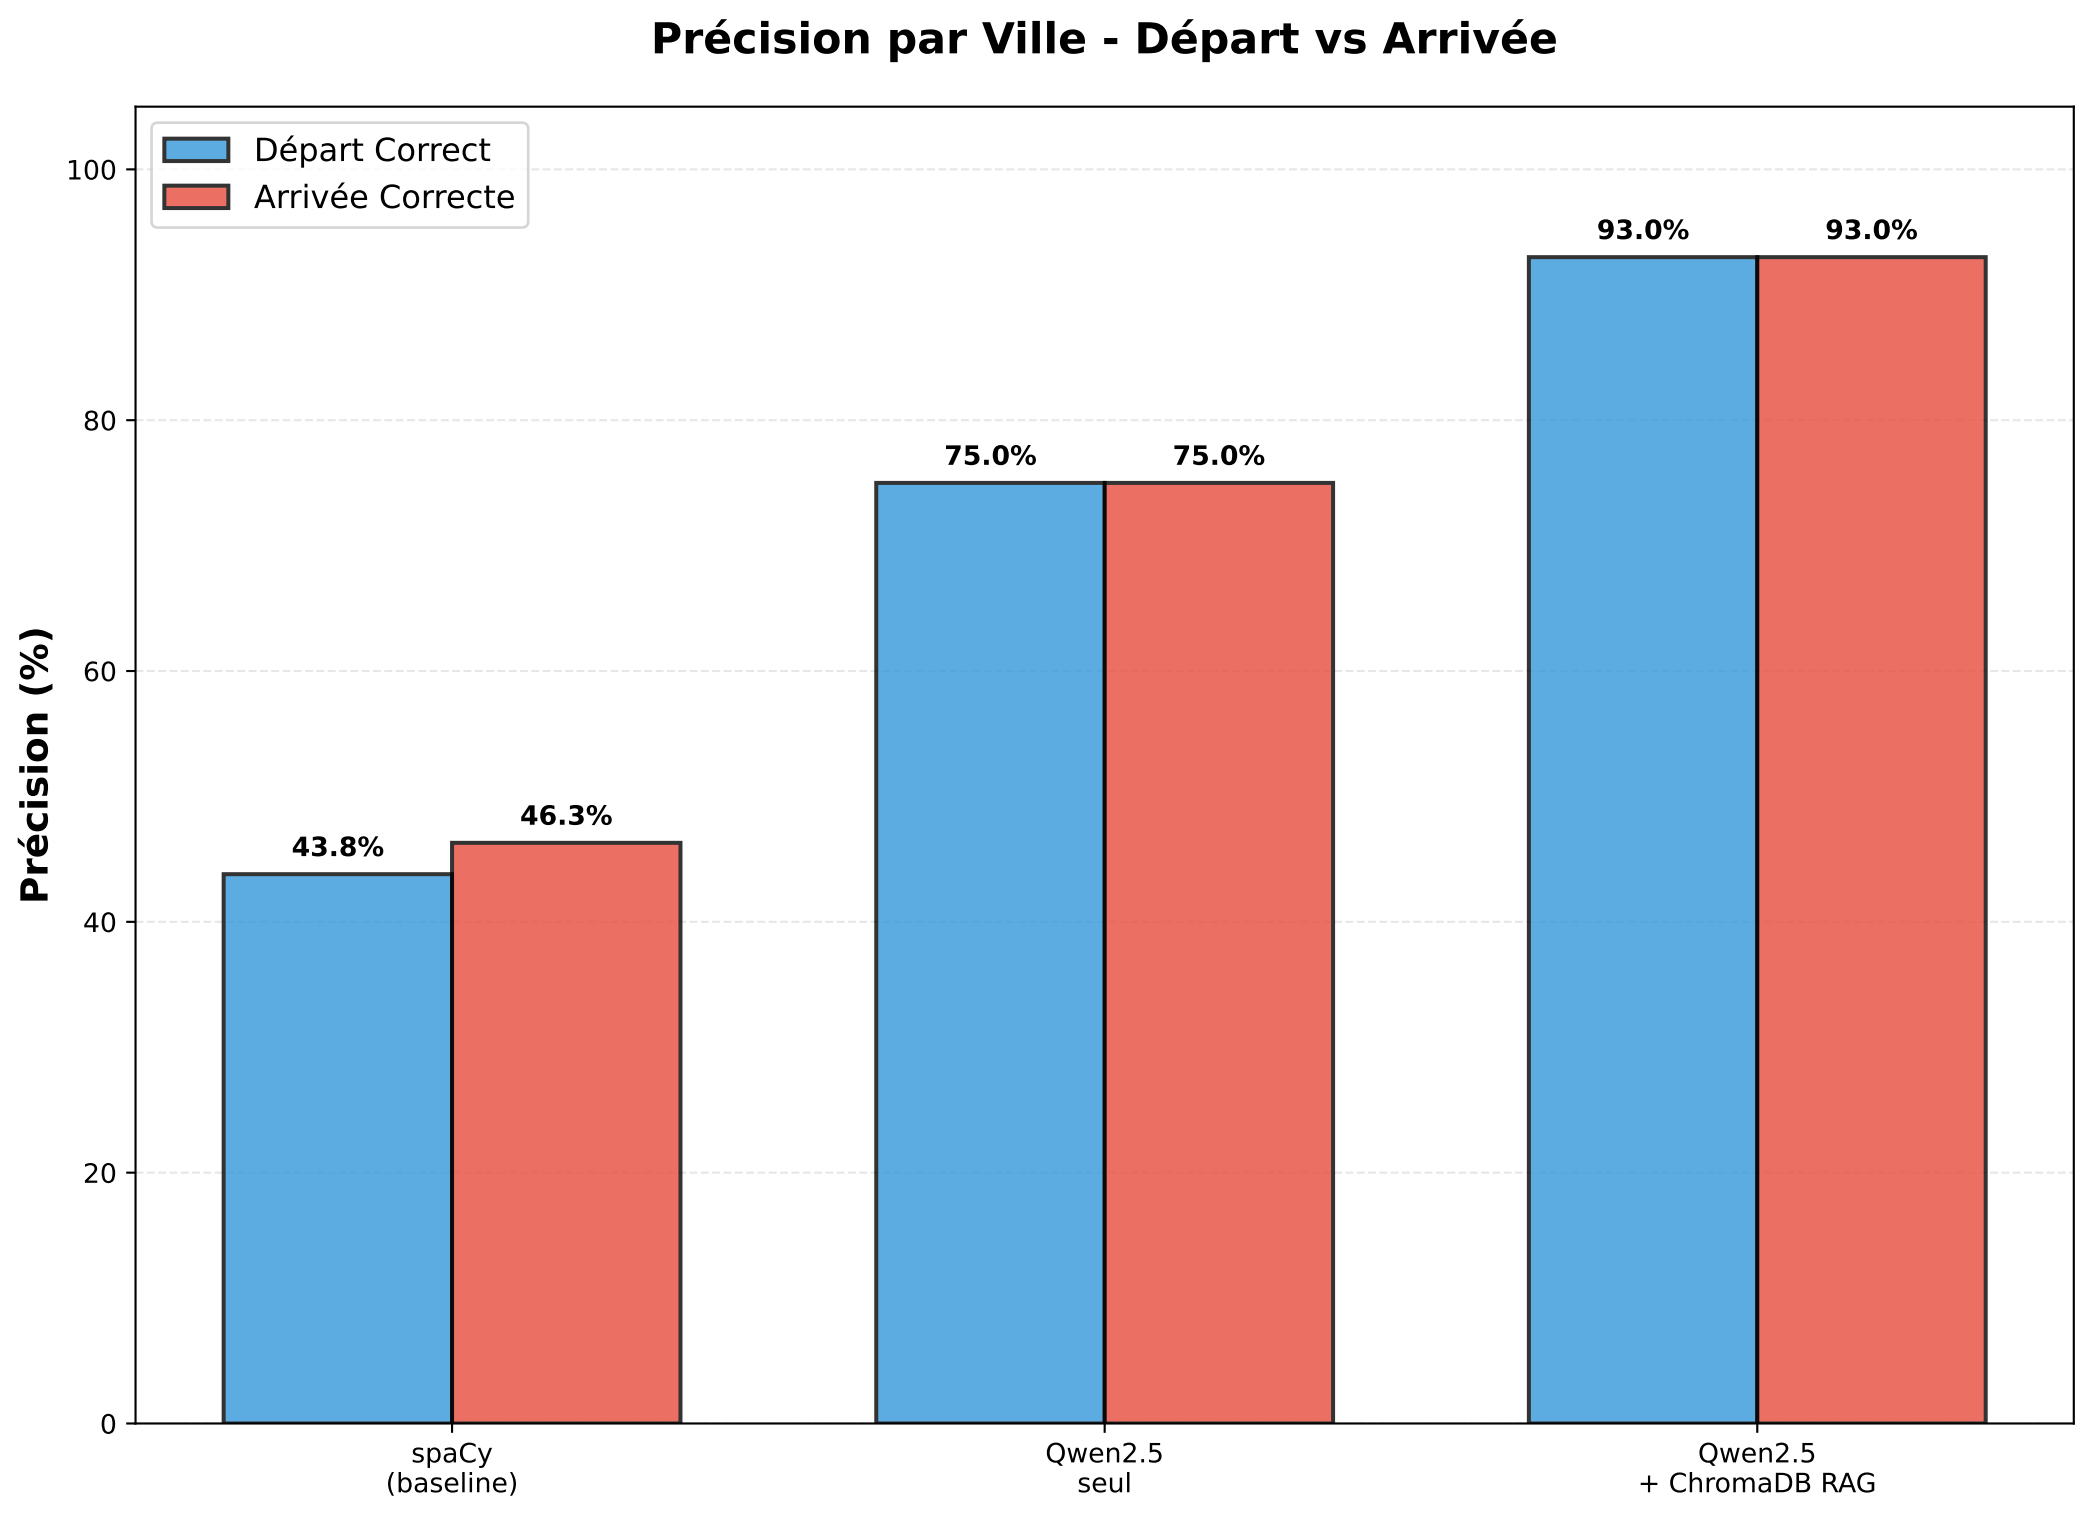
📈 Amélioration: +2.9x vs baseline spaCy

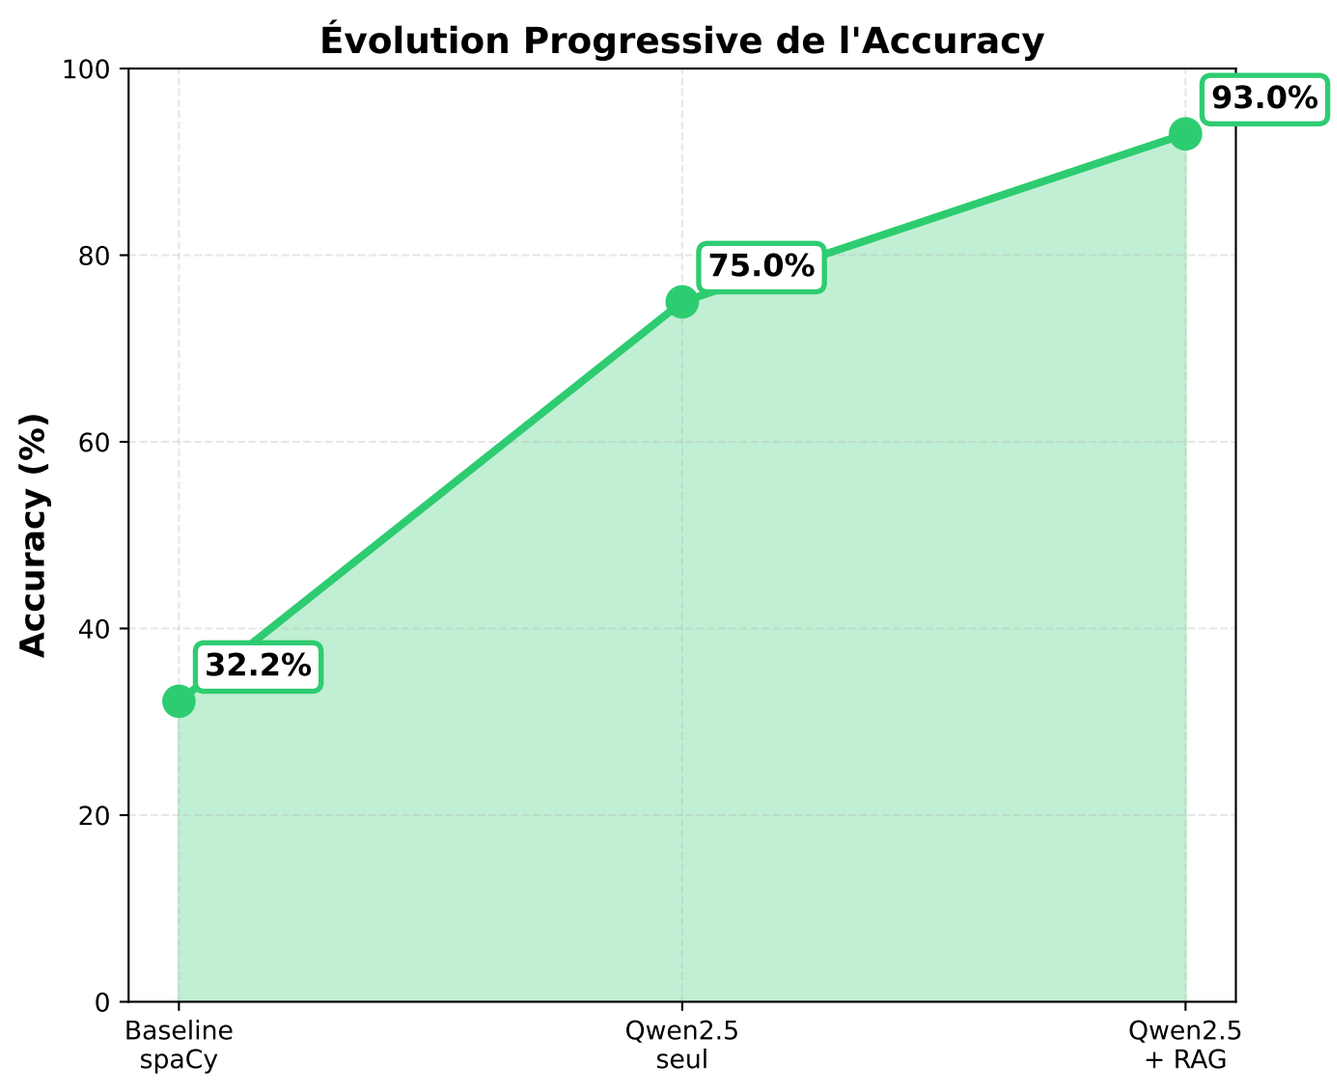
🚀 Impact RAG: +18 points (75% → 93%)

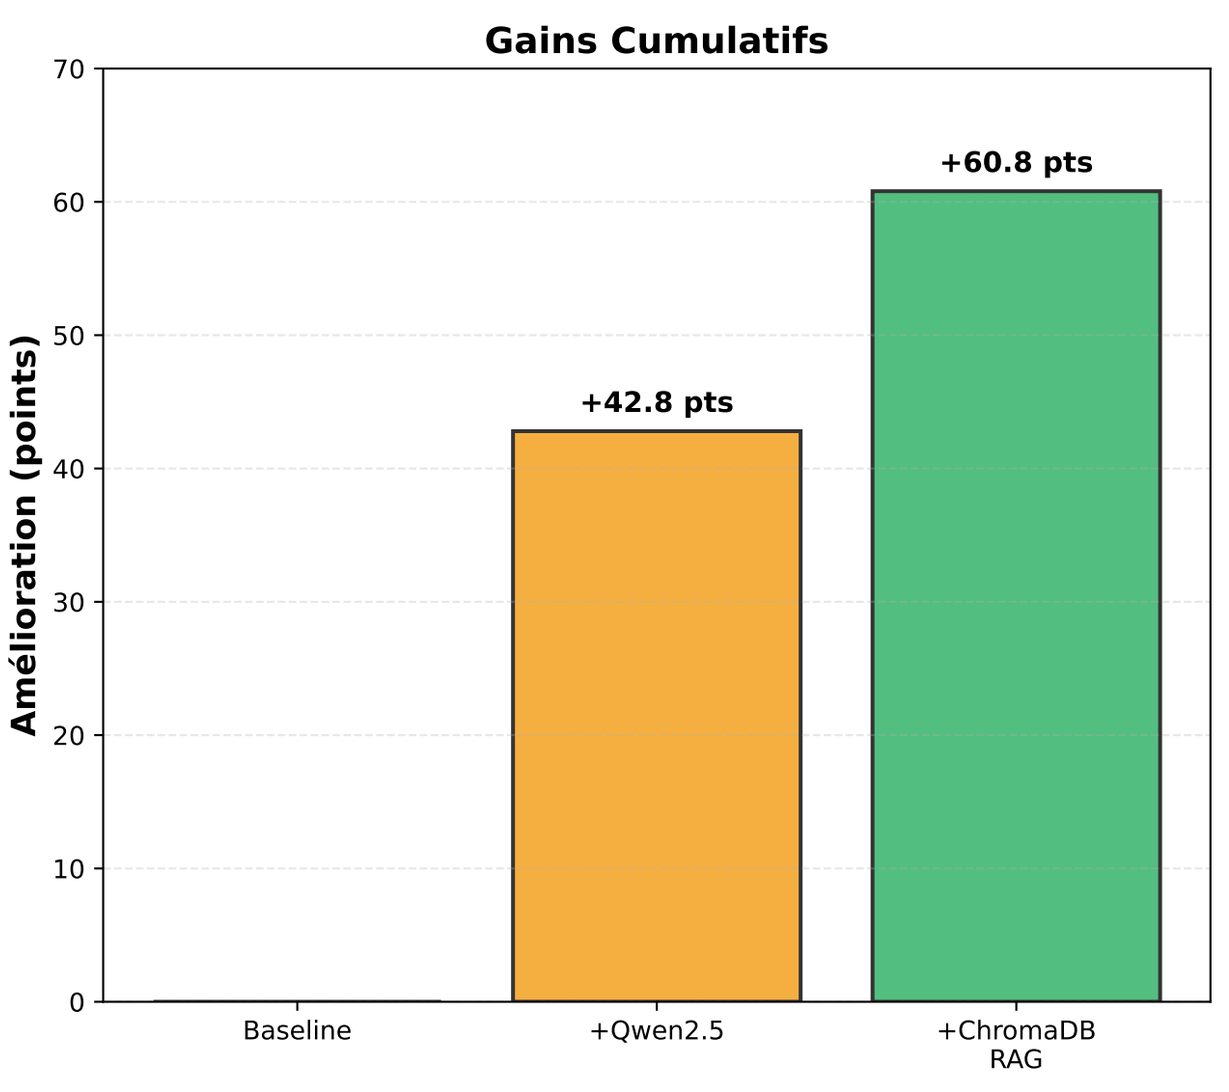
Projet: TAN-911-PAR_14

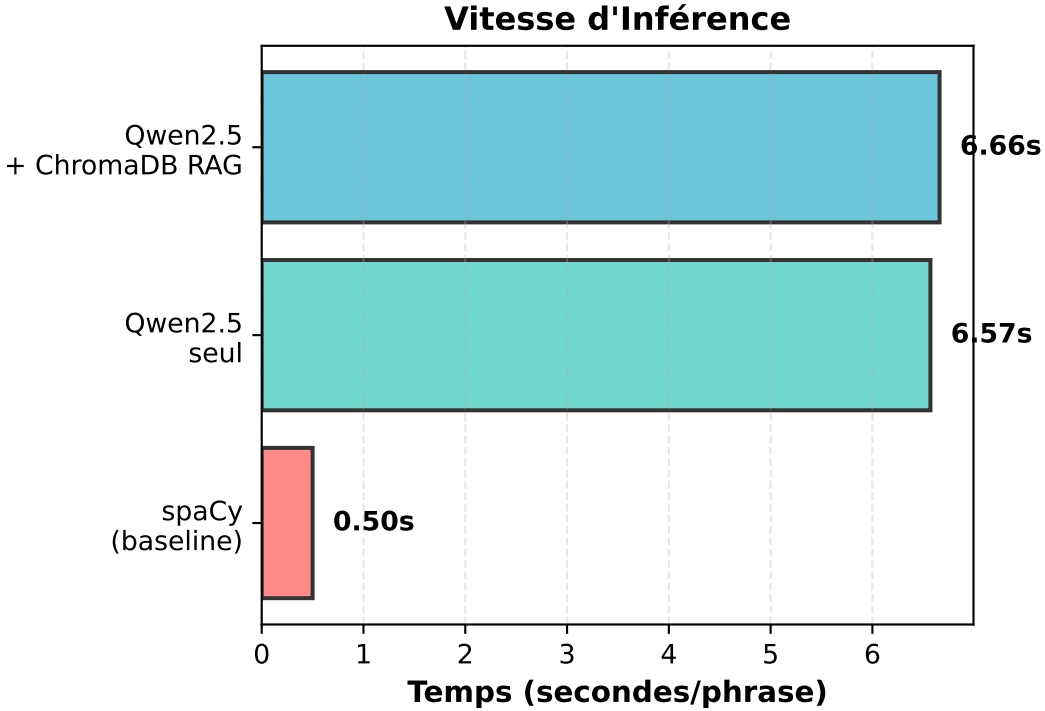
Date: 05/12/2025


Comparaison de l'Accuracy - Extraction de Villes
Objectif 90%
Accuracy (%)
100
80
60
40
20
0
32.2%
75.0%
93.0%
+42.8 pts
(2.3x)
+60.8 pts
(2.9x)
spaCy
(baseline)
Qwen2.5
seul
Qwen2.5
+ ChromaDB RAG


Précision par Ville - Départ vs Arrivée
Départ Correct
Arrivée Correcte
Précision (%)
0
20
40
60
80
100
43.8%
46.3%
75.0%
75.0%
93.0%
93.0%
spaCy
(baseline)
Qwen2.5
seul
Qwen2.5
+ ChromaDB RAG


Évolution Progressive de l'Accuracy
Accuracy (%)
100
80
60
40
20
0
32.2%
75.0%
93.0%
Baseline
spaCy
Qwen2.5
seul
Qwen2.5
+ RAG


Gains Cumulatifs
Amélioration (points)
70
60
50
40
30
20
10
0
+42.8 pts
+60.8 pts
Baseline
+Qwen2.5
+ChromaDB
RAG



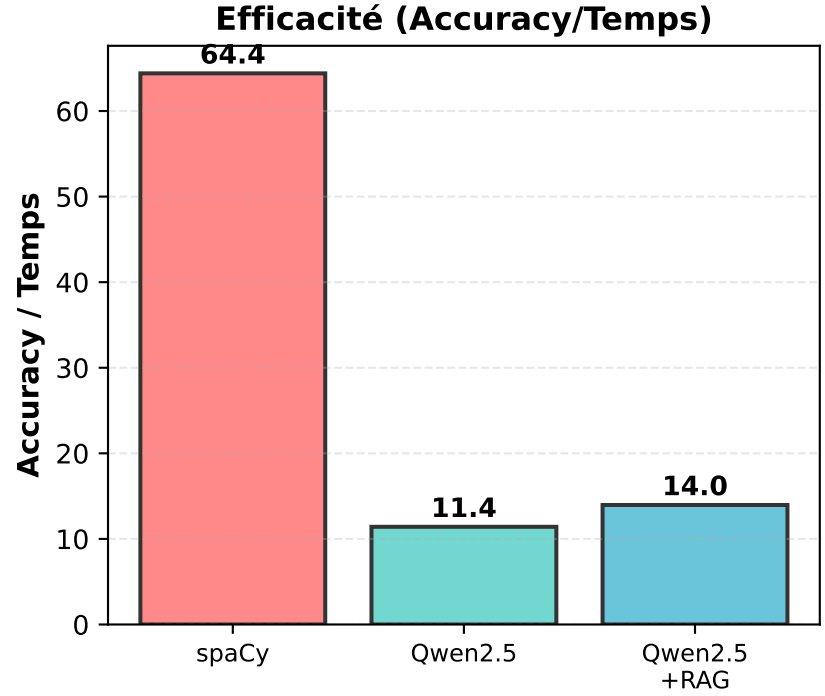


Tableau Récapitulatif des Performances

Approche	Accuracy	Départ	Arrivée	Temps/phrase	Amélioration
spaCy (baseline)	32.2%	43.8%	46.3%	0.5s	-
Qwen2.5 seul	75.0%	75.0%	75.0%	6.6s	+2.3x
Qwen2.5 + ChromaDB R	93.0%	93.0%	93.0%	6.7s	+2.9x

CONCLUSIONS & RECOMMANDATIONS

🎯 RÉSULTATS CLÉS

• Qwen2.5 + ChromaDB RAG atteint 93% d'accuracy (objectif dépassé)

• Amélioration de +2.9x par rapport à spaCy baseline

• Le RAG apporte un gain significatif de +18 points

• Infrastructure GPU opérationnelle (RTX 3060)

• Dataset de 10,000 phrases généré et validé

🚀 RECOMMANDATIONS

Pour la Production:

→ Utiliser Qwen2.5 + ChromaDB RAG (93% accuracy)

→ Optimiser avec batch processing

→ Déployer via API REST

Améliorations Futures:

→ Augmenter le dataset RAG à 1,000-5,000 phrases

→ Fine-tuning de Qwen2.5 avec LoRA/QLoRA

→ Optimisation GPU (quantization INT8)

→ Intégrer Flash Attention pour accélérer

📊 DÉTAILS TECHNIQUES

• Modèle: Qwen2.5-3B-Instruct (Alibaba)

• GPU: NVIDIA RTX 3060 Laptop (6GB VRAM)

• Framework: PyTorch 2.5.1 + CUDA 12.1

• Vector DB: ChromaDB avec embeddings multilingues

• Vitesse: 6.6 secondes/phrase sur GPU